

Projekt

Technologie webowe

Krzysztof Mizgała, album 262839

2024-12-20

Spis treści

Wprowadzenie	2
Cel projektu	2
Czym jest scrapowanie danych?	2
Dlaczego BoardGameGeek.com?	2
Struktura projektu	2
Scrapowanie danych	3
Przygotowanie środowiska	3
Uruchomienie scrapera	3
Proces scrapowania	4
Logowanie do serwisu	4
Pobieranie linków	4
Pobieranie danych o grach	4
Zabezpieczenia i optymalizacja	5
Zapisywanie danych	5
Zakończenie	5
Analiza danych	5
Struktura danych	6
Czyszczenie i przetwarzanie danych	7
Analiza statystyk opisowych	7
Analiza eksploracyjna	11
Wnioski	18

Modelowanie predykcyjne	19
Przygotowanie danych	19
Regresja liniowa	19
Ocena modelu	19
Ważność cech	20
Wnioski	20
Gradient Boosting	21
Ocena modelu	21
Ważność cech	22
Wnioski	23
Podsumowanie	23
Kluczowe wnioski z analizy danych	23
Modelowanie predykcyjne	24
Wnioski końcowe	24

Wprowadzenie

Cel projektu

Projekt polega na scrapowaniu danych o grach planszowych z serwisu [BoardGameGeek](#) oraz analizie tych danych. Dane są pobierane za pomocą skryptu w Pythonie, który wykorzystuje bibliotekę Selenium do nawigacji po stronie internetowej i pobierania informacji o grach. Zebrane dane są następnie analizowane przy użyciu różnych technik analizy danych i uczenia maszynowego.

Czym jest scrapowanie danych?

Scrapowanie danych, znane również jako web scraping, to proces automatycznego pobierania informacji ze stron internetowych. Wykorzystuje się do tego specjalne skrypty lub narzędzia, które nawigują po stronach, pobierają zawartość i przetwarzają ją w celu uzyskania potrzebnych danych. Scrapowanie danych jest szczególnie przydatne, gdy dane nie są dostępne w formie łatwo dostępnych plików do pobrania, ale są wyświetlane na stronach internetowych.

Dlaczego BoardGameGeek.com?

BoardGameGeek.com (BGG) jest jednym z najbardziej znanych i szanowanych serwisów internetowych poświęconych grom planszowym. Strona ta jest szeroko uznawana za jedno z głównych źródeł informacji o grach planszowych, zarówno wśród graczy, jak i wydawców oraz projektantów gier. Dzięki swojej popularności, BGG gromadzi ogromną ilość danych na temat gier planszowych, co czyni go idealnym źródłem do analizy.

Struktura projektu

- `scraper.py`: Skrypt do scrapowania danych z BoardGameGeek.
- `projekt.ipynb`: Notebook Jupyter zawierający kod do analizy danych.
- `games.csv`: Plik CSV zawierający zebrane dane o grach planszowych.
- `raport.pdf`: Raport końcowy w formacie PDF.

Scrapowanie danych

Przygotowanie środowiska

Aby rozpocząć proces scrapowania danych, należy spełnić następujące wymagania:

1. **Python 3.11:** Upewnij się, że masz zainstalowaną wersję Python 3.11.
2. **Google Chrome:** Zainstaluj przeglądarkę Google Chrome.
3. **ChromeDriver:** Pobierz [ChromeDriver](#) i umieść go w katalogu zawierającym plik `scraper.py` lub dodaj jego lokalizację do zmiennej środowiskowej `PATH`.
4. **Biblioteki Python:** Zainstaluj wymagane biblioteki, wykonując poniższe polecenie:

```
pip install -r requirements.txt
```

5. **Utwórz plik `.env`:** Utwórz plik `.env` w katalogu projektu i dodaj do niego swoje dane logowania do BoardGameGeek:

```
USER='twoja_nazwa_uzytkownika'  
PASS='twoje_haslo'
```

Uruchomienie scrapera

Aby uruchomić scraper i pobrać dane o grach planszowych, wykonaj poniższe polecenie w terminalu:

```
python scraper.py
```

Scraper posiada również następujące opcje wiersza poleceń (flagi):

- `-g` lub `--games`: liczba gier do pobrania (domyślnie 10000)
- `-c` lub `--checkpoint`: zapisuj dane co określoną liczbę gier (domyślnie 100)
- `-f` lub `--filename`: nazwa pliku do zapisu danych (domyślnie `games.csv`)

Na przykład, aby pobrać dane o 5000 grach, zapisywać dane co 50 gier w pliku `my_games.csv`:

```
python scraper.py -g 5000 -c 50 -f my_games.csv
```

Proces scrapowania

Logowanie do serwisu

- Skrypt `scraper.py` inicjalizuje obiekt klasy `Scraper`, który konfiguruje przeglądarkę Chrome w trybie headless (bez interfejsu graficznego).
- Po wejściu na stronę scraper automatycznie akceptuje pliki cookie.
- Scraper otwiera panel logowania BoardGameGeek. Logowanie jest konieczne, aby uzyskać pełen dostęp do danych.
- Logowanie odbywa się za pomocą danych użytkownika (nazwa użytkownika i hasło) pobranych z pliku `.env`.
- Selenium symuluje wypełnienie pól logowania oraz kliknięcie przycisku „Zaloguj”.

Pobieranie linków

Metoda `get_links` pobiera linki do stron z grami planszowymi. Na każdej podstronie rankingu wyświetlane jest 100 gier. W celu uzyskania wystarczającego zbioru danych do analizy, pobieramy dane ze 100 stron, co daje nam zbiór 10 tys. gier. Domyślnie gry są posortowane według oceny, zatem sortujemy je po liczbie ocen malejąco, aby uzyskać jak najbardziej wiarygodne wyniki.

Odwiedzamy kolejne strony rankingu, używając adresów URL zawierających numer strony. Linki są zapisywane w pliku `links.txt`, aby uniknąć ponownego pobierania w przypadku przerwania procesu.

Pobieranie danych o grach

Metoda `get_games` iteruje przez pobrane linki i dla każdej gry pobiera szczegółowe informacje. Dla każdej gry wykonano następujące kroki:

- Odwiedzano zakładkę z danymi statystycznymi (`/stats`) na stronie szczegółowej gry.
- Pobierano informacje o grze, w tym:
 - **Podstawowe dane:** nazwa gry, rok wydania, liczba graczy, czas rozgrywki, wymagany wiek, złożoność gry i alternatywne nazwy gry (jeśli istnieją).
 - **Opinie:** liczba ocen, średnia ocena, odchylenie standardowe oraz dokładny rozkład ocen w skali od 1 do 10.
 - **Statystyki:** liczba komentarzy, fanów, wyświetleń strony, liczba rozgrywek (ogółem i w bieżącym miesiącu).

- **Informacje o posiadaniu:** liczba osób posiadających grę, liczba chętnych na zakup lub wymianę.
- **Osoby zaangażowane:** projektanci, artyści i wydawcy.
- Wszystkie te informacje były wyodrębniane przy użyciu odpowiednich selektorów CSS i metod Selenium (`find_element` lub `find_elements`).
- Dane są zapisywane w formie słownika i dodawane do listy gier.
- W przypadku brakujących danych, skrypt zapisuje wartość `None`. Dodatkowa metoda `fill_missing` umożliwia ponowne odwiedzenie stron gier z brakującymi danymi w celu ich uzupełnienia (jeśli brak danych wynikał z błędu ładowania strony).

Zabezpieczenia i optymalizacja

- W przypadku problemów z ładowaniem strony (np. pusta strona lub opóźnienia serwera), skrypt wykonuje wielokrotne próby ponownego załadowania strony.
- Dla zabezpieczenia danych postęp scrapowania jest zapisywany regularnie, co umożliwia wznowienie pracy od ostatniego zarejestrowanego punktu kontrolnego.
- W celu zmniejszenia ryzyka blokady przez serwer BoardGameGeek, wprowadzono losowe opóźnienia między zapytaniami (od 2 do 10 sekund).

Zapisywanie danych

Dane są zapisywane w pliku `games.csv` co określoną liczbę gier (domyślnie co 100 gier), aby zapewnić bezpieczeństwo danych w przypadku przerwania procesu. Format CSV pozwala na łatwe wczytanie danych do analizy przy użyciu biblioteki `pandas`.

Zakończenie

Po zakończeniu procesu scrapowania, przeglądarka Chrome jest zamykana, a dane są gotowe do analizy.

Analiza danych

Strona BoardGameGeek ma 10-stopniową skalę oceniania gier planszowych. Gry oceniane są od 1 do 10, gdzie 1 oznacza najgorszą ocenę, a 10 najlepszą.

Zbadamy cechy gier, które mają wpływ na ich lepszą ocenę oraz cechy, które wpływają na największą spójność ocen (czyli czy gra jest oceniana podobnie przez różnych użytkowników). W następnej sekcji spróbujemy także stworzyć modele predykcyjne, które będą przewidywać jak może być oceniana gra na podstawie jej cech.

Struktura danych

Pierwszym krokiem analizy jest wczytanie danych z pliku `games.csv`, uzyskanego w wyniku scrapowania.

```
df = read_games()
df.shape
```

(10000, 36)

Mamy przygotowane dane 10 tys. wierszy i 36 kolumn, z których 6 to zmienne kategoryczne, a 30 to kolumny z danymi liczbowymi. Zebrane dane zawierają następujące kolumny:

1. Podstawowe informacje:

- Nazwa (name)
- Rok wydania (year)
- Opis (description)
- Wymagana liczba graczy (min_players, max_players)
- Czas gry (min_playtime, max_playtime)
- Wymagany wiek (min_age)
- Złożoność gry (complexity)
- Alternatywne nazwy (alternate_names)
- Projektanci (designers)
- Artyści (artists)
- Wydawcy (publishers)

2. Opinie:

- Liczba ocen (ratings)
- Średnia ocena (avg_rating)
- Odchylenie standardowe (std_rating)
- Rozkład ocen (ratings_1, ratings_2, ..., ratings_10)

3. Statystyki gry:

- Liczba komentarzy (comments)
- Liczba fanów (fans)
- Wyświetlenia strony (page_views)

4. Statystyki rozgrywek:

- Liczba rozgrywek (plays)
- Liczba rozgrywek w tym miesiącu (plays_month)

5. Dane na temat posiadania gry:

- Liczba osób posiadających grę (owners)
- Liczba osób, które posiadały grę (prev_owned)
- Liczba osób, które chcą sprzedać grę (for_trade)
- Liczba osób, które chcą kupić grę (want_in_trade)
- Liczba osób, które mają grę na liście życzeń (wishlist)

Czyszczenie i przetwarzanie danych

Usuujemy kolumnę `description` ponieważ nie wykorzystujemy jej w analizie.

```
df = df.drop(columns=['description'])
```

Usuujemy wiersze z brakującymi danymi.

```
df = df.dropna()
```

Konwertujemy zmienne na odpowiednie typy danych.

```
df[cols_float] = df[cols_float].astype(np.float32)
df[cols_int] = df[cols_int].astype(np.int32)
df[cols_list] = df[cols_list].map(lambda x: [i.strip(',') for i in x])
```

Analiza statystyk opisowych

Tabela 1: Statystyki opisowe dla zmiennych liczbowych

	mean	std	min	25%	50%	75%	max
year	2006.23	120.418	-3500	2008	2015	2019	2025
min_players	1.88633	0.723886	1	1	2	2	9
max_players	5.69612	8.80932	1	4	4	6	100
min_play_time	55.0787	89.0258	1	30	45	60	5400
max_play_time	84.0628	239.606	1	30	60	90	12000
min_age	10.8906	2.58212	2	8	12	13	21
complexity	2.24183	0.799187	1	1.63	2.17	2.77	4.86
ratings	2701.97	6748.38	324	505	896	2075	131155
avg_rating	6.96794	0.797025	2.747	6.467	6.985	7.522	9.387
std_rating	1.39917	0.204331	0.95	1.26	1.37	1.51	4.03
ratings_1	10.5343	43.2513	1	2	3	7	2233
ratings_2	17.8127	68.173	1	3	7	15	4185
ratings_3	37.2363	110.332	1	8	17	34	5894
ratings_4	81.7612	199.653	1	20	41	79	8042
ratings_5	176.245	348.026	1	51	94	174	8601
ratings_6	477.891	1010.47	0	119	201	430	26381
ratings_7	660.714	1637.91	0	114	221	544	37689
ratings_8	780.537	2323.82	0	67	171	538	46243
ratings_9	294.303	1090.56	0	17	52	173	28049
ratings_10	168.302	778.607	0	4	22	86	24892
comments	589.319	1130.14	29	159	264	536	22457
fans	193.464	506.124	0	27	61	158	10951
page_views	268752	504472	8836	71228	127706	258999	1.32543e+07
plays	10048.1	36621.6	0	938	2131	5880	837775
plays_month	46.4011	209.377	0	1	4	20	5933
owners	5221.8	10370.4	27	1293	2380	5016	215312
prev_owned	585.955	937.895	3	161	296	616	15111
for_trade	109.746	158.979	0	34	63	123	3202
want_in_trade	105.761	164.497	0	23	53	117	1983
wishlist	703.45	1456.57	5	124	267	640	24480

- Średnia liczba ocen to około 2702, co wskazuje na dużą popularność gier.
- Średnia ocena to 6.97, co sugeruje, że większość gier jest dobrze oceniana.
- Wartości **year** mogą być ujemne (min: -3500), co oznacza wydanie gry przed naszą erą, uwzględnimy to podczas dalszej analizy.

Sprawdźmy jakie są najczęściej występujące wartości w kolumnach z danymi kategorycznymi.

Tabela 2: Najczęściej występujący projektanci gier planszowych

Projektant	Liczba gier
Reiner Knizia	219
(Uncredited)	199
Eric M. Lang	107
Bruno Cathala	99
Wolfgang Kramer	88
Nate French	81
Uwe Rosenberg	80
Rob Daviau	80
Klaus Teuber	76
Antoine Bauza	75

Wiele gier ma nieznanego projektanta, są to głównie starsze gry, dla których trudno jest znaleźć dokładne informacje.

Tabela 3: Najczęściej występujący artyści gier planszowych

Artysta	Liczba gier
Franz Vohwinkel	169
Fantasy Flight Games	141
Michael Menzel	128
Klemens Franz	118
GMT Games	100
Hasbro	99
Harald Lieske	94
The Avalon Hill Game Co	93
Cyrille Daujean	84
(Uncredited)	82


Tabela 4: Najczęściej występujący wydawcy gier planszowych

Wydawca	Liczba gier
Fantasy Flight Games	527
KOSMOS	244
Rio Grande Games	201
Edge Entertainment	194

Wydawca	Liczba gier
Hasbro	194
Pegasus Spiele	174
Ravensburger	172
999 Games	168
Asmodee	158
GMT Games	154

Wśród wydawców wyróżnia się Fantasy Flight Games, co nie jest zaskoczeniem, biorąc pod uwagę popularność ich gier.


Analiza eksploracyjna



Rysunek 1: Rozkład ocen gier planszowych

- Najwięcej ocen znajduje się w przedziale 7-8. Oznacza to, że gry planszowe są najczęściej oceniane jako dobre lub bardzo dobre.
- Liczba ocen gwałtownie spada w skrajnych przedziałach. Sugeruje to, że gry planszowe rzadko otrzymują skrajnie niskie lub skrajnie wysokie oceny.
- Rozkład ocen nie jest symetryczny. Może to sugerować, że oceniający są bardziej skłonni do dawania ocen w górnym zakresie skali, ale nie najwyższych możliwych ocen.

Korelacje między zmiennymi numerycznymi



Rysunek 2: Macierz korelacji między zmiennymi numerycznymi

Zwróćmy szczególną uwagę na korelacje zmiennej **avg_rating** z innymi zmiennymi. Najbardziej skorelowana jest zmienna **complexity**, co sugeruje, że złożoność gry ma wpływ na jej ocenę.

Odchylenie standardowe **std_rating** nie wykazuje silnych korelacji z innymi zmiennymi, co sugeruje, że różnorodność ocen nie jest silnie związana z innymi cechami gry.

Tabela 5: Najczęściej oceniane gry planszowe i ich oceny

Gra	Średnia ocena	Liczba ocen
CATAN	7.096	131155
Carcassonne	7.41	130119
Pandemic	7.531	128082
7 Wonders	7.677	106778
Terraforming Mars	8.353	102723
7 Wonders Duel	8.093	98410
Wingspan	8.033	98163
Codenames	7.536	94966
Azul	7.738	94842
Dominion	7.598	92475


Najpopularniejsze gry planszowe mają bardzo wysokie oceny, wskazując na ich wysoką jakość w oczach graczy.

Tabela 6: Najlepsi projektanci gier planszowych według średniej oceny

Projektant	Średnia ocena
Volodymyr Semeniv	9.099
Michał Lach	8.938
Konrad Sulżycki	8.938
Jamie Jolly	8.927
Robert Butler	8.857
Casey Yano	8.769
Anthony Giovannetti	8.769
George Krubski	8.756
Joe Kepler	8.756
Gina Willis	8.744


Najlepsi projektanci gier planszowych według średniej oceny to głównie znani i cenieni twórcy.

Pokażemy kilka interesujących zależności między zmiennymi:




Rysunek 3: Złożoność w stosunku do średniej oceny

Jak wcześniej sugerowała macierz korelacji, złożoność gry ma wpływ na jej ocenę. Widać tendencję, że gry o większej złożoności są lepiej oceniane.



Rysunek 4: Liczba fanów w stosunku do średniej oceny


Słabo oceniane gry mają bardzo małą liczbę fanów. Gry z dużą liczbą fanów są zazwyczaj dobrze oceniane.



Rysunek 5: Minimalna liczba graczy w stosunku do średniej oceny


Jeśli minimalna liczba graczy jest większa niż 4 to jest praktycznie pewne, że gra będzie dobrze oceniana.

Z drugiej strony lepiej oceniane są średnio gry, w które można samemu, niż te, które wymagają większej liczby graczy.



Rysunek 6: Średnia ocena gier planszowych na przestrzeni lat (od 1900 roku)

Na wykresie pokazujemy jedynie gry wydane po 1900 roku, gdyż jest bardzo mało gier z wcześniejszych lat. Widać, że w ostatnich latach gry planszowe są coraz lepiej oceniane, co może świadczyć o postępie w tej dziedzinie.



Rysunek 7: Średnia ocena gier planszowych według projektantów

Dla 20 najpopularniejszych projektantów gier planszowych, widać znaczące różnice w ocenach ich gier. Szczególnie widać, że słabo oceniane są gry z nieznanym projektantem.

Wnioski

Rynek gier planszowych dynamicznie się rozwija, co widać po wysokich ocenach i rosnącej popularności. Większość gier jest dobrze oceniana, z dominującym przedziałem 7-8, a bardziej złożone tytuły cieszą się szczególnym uznaniem. Najlepsze gry wyróżniają się wysoką jakością, a kluczową rolę odgrywają uznani wydawcy, tacy jak Fantasy Flight Games, oraz cenieni projektanci.

Ostatnie lata przyniosły wzrost jakości nowych gier, co pokazuje innowacyjność i rozwój branży. Zaangażowanie społeczności graczy potwierdza znaczenie gier planszowych jako popularnego i stale rosnącego medium rozrywkowego.

Modelowanie predykcyjne

W przypadku predykcji oceny gry, nie będziemy korzystać z żadnej ze zmiennych związanych z ocenami, aby uniknąć tzw. „data leakage” (wycieku danych).

Przygotowanie danych

W celu przygotowania danych do modelowania, dzielimy zbiór danych na zbiór treninowy i testowy w stosunku 80:20. Następnie wybieramy zbiór cech, które będą wykorzystane do predykcji oceny gry.

Regresja liniowa

Pierwszym modelem, który zastosujemy, jest regresja liniowa. Regresja liniowa jest jednym z najprostszych modeli regresji, który zakłada liniową zależność między zmiennymi niezależnymi a zmienną zależną.

```
model = LinearRegression()
model.fit(X_train, y_train)
y_pred = model.predict(X_test)
```


Ocena modelu

Tabela 7: Ocena modelu regresji liniowej


Metryka	Średni błąd kwadratowy
Średnia ocena	0.242679
Odchylenie standardowe ocen	0.0355341

Regresja liniowa zakłada prostą, liniową relację między cechami a wynikami, co może prowadzić do niedoszacowania lub przeszacowania wpływu niektórych cech, szczególnie gdy dane mają charakter nieliniowy.

Ważność cech



Rysunek 8: Ważność cech w modelu regresji liniowej dla średniej oceny



Rysunek 9: Ważność cech w modelu regresji liniowej dla odchylenia standardowego ocen

Wnioski

- Zarówno średnia ocena, jak i odchylenie standardowe ocen są w dużej mierze kształtowane przez cechy związane z twórcami gry (projektanci, artyści, wydawcy). Su-

geruje to, że renoma i liczba osób zaangażowanych w tworzenie gry mają kluczowe znaczenie.

- Złożoność gry jest istotnym czynnikiem dla średniej oceny, ale mniej wpływa na zróżnicowanie ocen. Gry o większej głębi mogą być bardziej doceniane, ale niekoniecznie wywołują większe kontrowersje wśród graczy.
- Statystyki dotyczące liczby rozgrywek, komentarzy czy wyświetleń strony mają marginalny wpływ, co może wskazywać, że czynniki związane z jakością gry są ważniejsze niż jej popularność.
- Parametry związane z wymianą i handlem grami mają zauważalny wpływ, co może być interesującą wskazówką dla twórców i wydawców, że popyt na rynku wtórnym może korelować z ocenami gry.

Gradient Boosting

Kolejnym modelem, który zastosujemy, jest Gradient Boosting. Gradient Boosting to technika uczenia maszynowego, która polega na łączeniu wielu słabych modeli predykcyjnych w celu uzyskania silnego modelu.

```
model = MultiOutputRegressor(GradientBoostingRegressor(random_state=314))
model.fit(X_train, y_train)
y_pred = model.predict(X_test)
```


Ocena modelu

Tabela 8: Ocena modelu Gradient Boosting


Metryka	Średni błąd kwadratowy
Średnia ocena	0.124526
Odchylenie standardowe ocen	0.027843

Model Gradient Boosting osiągnął znacznie niższy błąd, co wskazuje na lepszą zdolność przewidywania średniej oceny gry. Wynika to z elastyczności GB, który lepiej uwzględnia nieliniowe zależności i interakcje między cechami.

Ważność cech



Rysunek 10: Ważność cech w modelu Gradient Boosting dla średniej oceny



Rysunek 11: Ważność cech w modelu Gradient Boosting dla odchylenia standardowego ocen

Wnioski

- Model GB uwzględnia złożone i nieliniowe zależności między cechami, co pozwala mu lepiej wykorzystać dane. Dzięki temu cechy takie jak rynek wtórny (`for_trade`, `want_in_trade`) oraz popularność (`page_views`, `owners`) stają się bardziej istotne.
- Regresja liniowa nadmiernie polega na cechach o bezpośrednim wpływie, takich jak liczba projektantów czy artystów, podczas gdy pomija subtelne zależności w danych.
- W regresji liniowej dominują cechy silnie powiązane z jakością twórców (projektanci, artyści), podczas gdy GB lepiej uwzględnia popularność, rynek wtórny oraz nieliniowe relacje między cechami.
- Regresja liniowa może być użyteczna dla prostych interpretacji, podczas gdy Gradient Boosting jest bardziej odpowiedni do analizy złożonych zależności w danych.

Podsumowanie

Projekt polegał na scrapowaniu danych o grach planszowych z serwisu BoardGameGeek oraz analizie tych danych. Proces scrapowania został zrealizowany za pomocą skryptu w Pythonie, który wykorzystuje bibliotekę Selenium do nawigacji po stronie internetowej i pobierania informacji o grach. Zebrane dane zostały następnie poddane analizie przy użyciu różnych technik analizy danych i uczenia maszynowego.

Kluczowe wnioski z analizy danych

1. **Oceny gier:** Większość gier planszowych jest dobrze oceniana przez użytkowników, z największą liczbą ocen w przedziale 7-8.
2. **Złożoność gry:** Gry o większej złożoności są lepiej oceniane, co sugeruje, że gracze cenią bardziej skomplikowane i wymagające gry.
3. **Popularność:** Najpopularniejsze gry mają bardzo wysokie oceny, co wskazuje na ich wysoką jakość. Wydawcy tacy jak Fantasy Flight Games dominują na rynku.
4. **Trendy:** W ostatnich latach gry planszowe są coraz lepiej oceniane, co może świadczyć o postępie w tej dziedzinie i rosnącej jakości nowych gier.
5. **Projektanci:** Renoma projektantów, artystów i wydawców ma znaczący wpływ na oceny gier.

Modelowanie predykcyjne

1. **Regresja liniowa:** Model regresji liniowej wykazał, że cechy związane z twórcami gry mają kluczowe znaczenie dla średniej oceny i odchylenia standardowego ocen.
2. **Gradient Boosting:** Model Gradient Boosting osiągnął lepsze wyniki, uwzględniając złożone i nieliniowe zależności między cechami. Cechy takie jak popularność i rynek wtórny stały się bardziej istotne.

Wnioski końcowe

Analiza pokazuje, że rynek gier planszowych jest dynamiczny i rozwijający się, z rosnącą jakością gier i dużym zaangażowaniem społeczności graczy. Modele predykcyjne mogą być użyteczne w przewidywaniu ocen gier na podstawie ich cech, co może być cenną wskazówką dla twórców i wydawców gier planszowych.