

Projekt

Technologie webowe

Krzysztof Mizgała, album 262839

2024-12-20

Spis treści

Wprowadzenie	3
Cel projektu	3
Czym jest scrapowanie danych?	3
Dlaczego BoardGameGeek.com?	3
Przegląd technologii	3
Struktura projektu	4
Scrapowanie danych	4
Przygotowanie środowiska	4
Uruchomienie scrapera	5
Proces scrapowania	5
Logowanie do serwisu	5
Pobieranie linków	5
Pobieranie danych o grach	6
Zabezpieczenia i optymalizacja	6
Zapisywanie danych	7
Zakończenie	7
Analiza danych	7
Struktura danych	7
Czyszczenie i przetwarzanie danych	8
Analiza statystyk opisowych	9
Analiza eksploracyjna	12

Wyniki i wnioski	19
Modelowanie predykcyjne	19
Przygotowanie danych	19
Podsumowanie	20

Wprowadzenie

Cel projektu

Projekt polega na scrapowaniu danych o grach planszowych z serwisu [BoardGameGeek](#) oraz analizie tych danych. Dane są pobierane za pomocą skryptu w Pythonie, który wykorzystuje bibliotekę Selenium do nawigacji po stronie internetowej i pobierania informacji o grach. Zebrane dane są następnie analizowane przy użyciu różnych technik analizy danych i uczenia maszynowego.

Czym jest scrapowanie danych?

Scrapowanie danych, znane również jako web scraping, to proces automatycznego pobierania informacji ze stron internetowych. Wykorzystuje się do tego specjalne skrypty lub narzędzia, które nawigują po stronach, pobierają zawartość i przetwarzają ją w celu uzyskania potrzebnych danych. Scrapowanie danych jest szczególnie przydatne, gdy dane nie są dostępne w formie łatwo dostępnych plików do pobrania, ale są wyświetlane na stronach internetowych.

Dlaczego BoardGameGeek.com?

BoardGameGeek.com (BGG) jest jednym z najbardziej znanych i szanowanych serwisów internetowych poświęconych grom planszowym. Strona ta jest szeroko uznawana za jedno z głównych źródeł informacji o grach planszowych, zarówno wśród graczy, jak i wydawców oraz projektantów gier. Dzięki swojej popularności, BGG gromadzi ogromną ilość danych na temat gier planszowych, co czyni go idealnym źródłem do analizy.

Przegląd technologii

- Technologie i narzędzia użyte w projekcie (Python, Selenium, Pandas, Matplotlib).
- Krótka charakterystyka wybranych bibliotek i frameworków.
- **Biblioteki Python:** Selenium, pandas, tqdm, dotenv.

- **Przeglądarka:** Chrome (lub inna wspierana przez Selenium, z odpowiednim WebDriverem).
- **Plik .env:** Przechowuje dane logowania (USER i PASS) do serwisu BoardGameGeek.

Struktura projektu

- `scraper.py`: Skrypt do scrapowania danych z BoardGameGeek.
- `projekt.ipynb`: Notebook Jupyter zawierający kod do analizy danych.
- `games.csv`: Plik CSV zawierający zebrane dane o grach planszowych.
- `raport.pdf`: Raport końcowy w formacie PDF.

Scrapowanie danych

Przygotowanie środowiska

Aby rozpocząć proces scrapowania danych, należy spełnić następujące wymagania:

1. **Python 3.11:** Upewnij się, że masz zainstalowaną wersję Python 3.11.
2. **Google Chrome:** Zainstaluj przeglądarkę Google Chrome.
3. **ChromeDriver:** Pobierz [ChromeDriver](#) i umieść go w katalogu zawierającym plik `scraper.py` lub dodaj jego lokalizację do zmiennej środowiskowej `PATH`.
4. **Biblioteki Python:** Zainstaluj wymagane biblioteki, wykonując poniższe polecenie:

```
pip install -r requirements.txt
```

5. **Utwórz plik .env:** Utwórz plik `.env` w katalogu projektu i dodaj do niego swoje dane logowania do BoardGameGeek:

```
USER='twoja_nazwa_uzytkownika'
PASS='twoje_haslo'
```

Uruchomienie scrapera

Aby uruchomić scraper i pobrać dane o grach planszowych, wykonaj poniższe polecenie w terminalu:

```
python scraper.py
```

Scraper posiada również następujące opcje wiersza poleceń (flagi):

- `-g` lub `--games`: liczba gier do pobrania (domyślnie 10000)
- `-c` lub `--checkpoint`: zapisuj dane co określoną liczbę gier (domyślnie 100)
- `-f` lub `--filename`: nazwa pliku do zapisu danych (domyślnie `games.csv`)

Na przykład, aby pobrać dane o 5000 grach, zapisywać dane co 50 gier w pliku `my_games.csv`:

```
python scraper.py -g 5000 -c 50 -f my_games.csv
```

Proces scrapowania

Logowanie do serwisu

- Skrypt `scraper.py` inicjalizuje obiekt klasy `Scraper`, który konfiguruje przeglądarkę Chrome w trybie headless (bez interfejsu graficznego).
- Po wejściu na stronę scraper automatycznie akceptuje pliki cookie.
- Scraper otwiera panel logowania BoardGameGeek. Logowanie jest konieczne, aby uzyskać pełen dostęp do danych.
- Logowanie odbywa się za pomocą danych użytkownika (nazwa użytkownika i hasło) pobranych z pliku `.env`.
- Selenium symuluje wypełnienie pól logowania oraz kliknięcie przycisku „Zaloguj”.

Pobieranie linków

Metoda `get_links` pobiera linki do stron z grami planszowymi. Na każdej podstronie rankingu wyświetlane jest 100 gier. W celu uzyskania wystarczającego zbioru danych do analizy, pobieramy dane ze 100 stron, co daje nam zbiór 10 tys. gier. Domyślnie gry są posortowane według oceny, zatem sortujemy je po liczbie ocen malejąco, aby uzyskać jak najbardziej wiarygodne wyniki.

Odwiedzamy kolejne strony rankingu, używając adresów URL zawierających numer strony. Linki są zapisywane w pliku `links.txt`, aby uniknąć ponownego pobierania w przypadku przerwania procesu.

Pobieranie danych o grach

Metoda `get_games` iteruje przez pobrane linki i dla każdej gry pobiera szczegółowe informacje. Dla każdej gry wykonano następujące kroki:

- Odwiedzano zakładkę z danymi statystycznymi (`/stats`) na stronie szczegółowej gry.
- Pobierano informacje o grze, w tym:
 - **Podstawowe dane:** nazwa gry, rok wydania, liczba graczy, czas rozgrywki, wymagany wiek, złożoność gry i alternatywne nazwy gry (jeśli istnieją).
 - **Opinie:** liczba ocen, średnia ocena, odchylenie standardowe oraz dokładny rozkład ocen w skali od 1 do 10.
 - **Statystyki:** liczba komentarzy, fanów, wyświetleń strony, liczba rozgrywek (ogółem i w bieżącym miesiącu).
 - **Informacje o posiadaniu:** liczba osób posiadających grę, liczba chętnych na zakup lub wymianę.
 - **Osoby zaangażowane:** projektanci, artyści i wydawcy.
- Wszystkie te informacje były wyodrębniane przy użyciu odpowiednich selektorów CSS i metod Selenium (`find_element` lub `find_elements`).
- Dane są zapisywane w formie słownika i dodawane do listy gier.
- W przypadku brakujących danych, skrypt zapisuje wartość `None`. Dodatkowa metoda `fill_missing` umożliwia ponowne odwiedzenie stron gier z brakującymi danymi w celu ich uzupełnienia (jeśli brak danych wynikał z błędu ładowania strony).

Zabezpieczenia i optymalizacja

- W przypadku problemów z ładowaniem strony (np. pusta strona lub opóźnienia serwera), skrypt wykonuje wielokrotne próby ponownego załadowania strony.
- Dla zabezpieczenia danych postęp scrapowania jest zapisywany regularnie, co umożliwia wznowienie pracy od ostatniego zarejestrowanego punktu kontrolnego.
- W celu zmniejszenia ryzyka blokady przez serwer BoardGameGeek, wprowadzono losowe opóźnienia między zapytaniami (od 2 do 10 sekund).

Zapisywanie danych

Dane są zapisywane w pliku `games.csv` co określoną liczbę gier (domyślnie co 100 gier), aby zapewnić bezpieczeństwo danych w przypadku przerwania procesu. Format CSV pozwala na łatwe wczytanie danych do analizy przy użyciu biblioteki `pandas`.

Zakończenie

Po zakończeniu procesu scrapowania, przeglądarka Chrome jest zamykana, a dane są gotowe do analizy.

Analiza danych

Strona BoardGameGeek ma 10-stopniową skalę oceniania gier planszowych. Gry oceniane są od 1 do 10, gdzie 1 oznacza najgorszą ocenę, a 10 najlepszą.

Zbadamy cechy gier, które mają wpływ na ich lepszą ocenę oraz cechy, które wpływają na największą spójność ocen (czyli czy gra jest oceniana podobnie przez różnych użytkowników). W następnej sekcji spróbujemy także stworzyć modele predykcyjne, które będą przewidywać jak może być oceniana gra na podstawie jej cech.

Struktura danych

Pierwszym krokiem analizy jest wczytanie danych z pliku `games.csv`, uzyskanego w wyniku scrapowania.

```
df = read_games()
df.shape
```

```
(10000, 36)
```

Mamy przygotowane dane 10 tys. wierszy i 36 kolumn, z których 6 to zmienne kategoryczne, a 30 to kolumny z danymi liczbowymi. Zebrane dane zawierają następujące kolumny:

1. Podstawowe informacje:

- Nazwa (name)
- Rok wydania (year)
- Opis (description)
- Wymagana liczba graczy (min_players, max_players)
- Czas gry (min_playtime, max_playtime)
- Wymagany wiek (min_age)
- Złożoność gry (complexity)
- Alternatywne nazwy (alternate_names)
- Projektanci (designers)
- Artyści (artists)
- Wydawcy (publishers)

2. Opinie:

- Liczba ocen (ratings)
- Średnia ocena (avg_rating)
- Odchylenie standardowe (std_rating)
- Rozkład ocen (ratings_1, ratings_2, ..., ratings_10)

3. Statystyki gry:

- Liczba komentarzy (comments)
- Liczba fanów (fans)
- Wyświetlenia strony (page_views)

4. Statystyki rozgrywek:

- Liczba rozgrywek (plays)
- Liczba rozgrywek w tym miesiącu (plays_month)

5. Dane na temat posiadania gry:

- Liczba osób posiadających grę (owners)
- Liczba osób, które posiadały grę (prev_owned)
- Liczba osób, które chcą sprzedać grę (for_trade)
- Liczba osób, które chcą kupić grę (want_in_trade)
- Liczba osób, które mają grę na liście życzeń (wishlist)

Czyszczenie i przetwarzanie danych

Usuujemy kolumnę `description` ponieważ nie wykorzystujemy jej w analizie.


```
df = df.drop(columns=['description'])
```

Usuujemy wiersze z brakującymi danymi.

```
df = df.dropna()
```

Konwertujemy zmienne na odpowiednie typy danych.

```
df[cols_float] = df[cols_float].astype(np.float32)
df[cols_int] = df[cols_int].astype(np.int32)
df[cols_list] = df[cols_list].map(lambda x: [i.strip(',') for i in x])
```

Analiza statystyk opisowych

Tabela 1: Statystyki opisowe dla zmiennych liczbowych

	mean	std	min	25%	50%	75%	max
year	2006.23	120.418	-3500	2008	2015	2019	2025
min_players	1.88633	0.723886	1	1	2	2	9
max_players	5.69612	8.80932	1	4	4	6	100
min_play_time	55.0787	89.0258	1	30	45	60	5400
max_play_time	84.0628	239.606	1	30	60	90	12000
min_age	10.8906	2.58212	2	8	12	13	21
complexity	2.24183	0.799187	1	1.63	2.17	2.77	4.86
ratings	2701.97	6748.38	324	505	896	2075	131155
avg_rating	6.96794	0.797025	2.747	6.467	6.985	7.522	9.387
std_rating	1.39917	0.204331	0.95	1.26	1.37	1.51	4.03
ratings_1	10.5343	43.2513	1	2	3	7	2233
ratings_2	17.8127	68.173	1	3	7	15	4185
ratings_3	37.2363	110.332	1	8	17	34	5894
ratings_4	81.7612	199.653	1	20	41	79	8042
ratings_5	176.245	348.026	1	51	94	174	8601
ratings_6	477.891	1010.47	0	119	201	430	26381
ratings_7	660.714	1637.91	0	114	221	544	37689
ratings_8	780.537	2323.82	0	67	171	538	46243
ratings_9	294.303	1090.56	0	17	52	173	28049
ratings_10	168.302	778.607	0	4	22	86	24892

	mean	std	min	25%	50%	75%	max
comments	589.319	1130.14	29	159	264	536	22457
fans	193.464	506.124	0	27	61	158	10951
page_views	268752	504472	8836	71228	127706	258999	1.32543e+07
plays	10048.1	36621.6	0	938	2131	5880	837775
plays_month	46.4011	209.377	0	1	4	20	5933
owners	5221.8	10370.4	27	1293	2380	5016	215312
prev_owned	585.955	937.895	3	161	296	616	15111
for_trade	109.746	158.979	0	34	63	123	3202
want_in_trade	105.761	164.497	0	23	53	117	1983
wishlist	703.45	1456.57	5	124	267	640	24480

Najczęściej występujące wartości w kolumnach z danymi kategorycznymi.

Tabela 2: Najczęściej występujący projektanci gier planszowych

Projektant	Liczba gier
Reiner Knizia	219
(Uncredited)	199
Eric M. Lang	107
Bruno Cathala	99
Wolfgang Kramer	88
Nate French	81
Uwe Rosenberg	80
Rob Daviau	80
Klaus Teuber	76
Antoine Bauza	75

Tabela 3: Najczęściej występujący artyści gier planszowych


Artysta	Liczba gier
Franz Vohwinkel	169
Fantasy Flight Games	141
Michael Menzel	128
Klemens Franz	118
GMT Games	100
Hasbro	99
Harald Lieske	94

Artysta	Liczba gier
The Avalon Hill Game Co	93
Cyrille Daujean	84
(Uncredited)	82

Tabela 4: Najczęściej występujący wydawcy gier planszowych

Wydawca	Liczba gier
Fantasy Flight Games	527
KOSMOS	244
Rio Grande Games	201
Edge Entertainment	194
Hasbro	194
Pegasus Spiele	174
Ravensburger	172
999 Games	168
Asmodee	158
GMT Games	154

Analiza eksploracyjna



Rysunek 1: Rozkład ocen gier planszowych

Korelacje między zmiennymi numerycznymi




Tabela 5: Najczęściej oceniane gry planszowe i ich oceny

Gra	Średnia ocena	Liczba ocen
CATAN	7.096	131155
Carcassonne	7.41	130119
Pandemic	7.531	128082
7 Wonders	7.677	106778
Terraforming Mars	8.353	102723
7 Wonders Duel	8.093	98410
Wingspan	8.033	98163
Codenames	7.536	94966
Azul	7.738	94842
Dominion	7.598	92475

Gra	Średnia ocena	Liczba ocen
-----	---------------	-------------


TODO: Liczba gier do projektantów

Tabela 6: Najlepsi projektanci gier planszowych według średniej oceny


Projektant	Średnia ocena
Volodymyr Semeniv	9.099
Michał Lach	8.938
Konrad Sulżycki	8.938
Jamie Jolly	8.927
Robert Butler	8.857
Casey Yano	8.769
Anthony Giovannetti	8.769
George Krubski	8.756
Joe Kepler	8.756
Gina Willis	8.744

- Cel analizy (np. zidentyfikowanie najpopularniejszych gier, analiza ocen w zależności od liczby graczy).
- Metody analizy (np. statystyki opisowe, wizualizacje).
- Szczegółowe wyniki:
 - Wykresy, tabele, wnioski.
 - Przykłady interesujących zależności.


Interesujące zależności:




Rysunek 2: Złożoność w stosunku do średniej oceny



Rysunek 3: Liczba fanów w stosunku do średniej oceny




Rysunek 4: Minimalna liczba graczy w stosunku do średniej oceny



Rysunek 5: Średnia ocena gier planszowych na przestrzeni lat (od 1900 roku)

Średnia ocena w zależności od projektanta (20 najpopularniejszych)



Rysunek 6: Średnia ocena gier planszowych według projektantów

Wyniki i wnioski

- Podsumowanie najważniejszych wyników analizy.
- Interpretacja wyników w kontekście tematyki gier planszowych.

Modelowanie predykcyjne

W przypadku predykcji oceny gry, nie będziemy korzystać z żadnej ze zmiennych związanych z ocenami, aby uniknąć tzw. „data leakage” (wycieku danych).

Przygotowanie danych

Ellipsis

Podsumowanie

Wnioski końcowe

- Refleksje nad procesem realizacji projektu.
- Możliwości ulepszenia scrapera i analizy w przyszłości.

Zastosowania Scrapera:

1. Analiza gier planszowych

Dane zebrane przez scraper mogą być wykorzystane do analiz popularności, ocen i statystyk związanych z grami planszowymi.

2. Tworzenie rekomendacji

Informacje o ocenach i opiniach użytkowników mogą służyć do budowania systemów rekomendacyjnych.

3. Porównania i statystyki rynkowe

Zebrane dane umożliwiają identyfikację trendów w branży gier planszowych, popularnych projektantów czy wydawców.

4. Tworzenie baz danych

Dzięki zapisowi danych w pliku CSV, możliwe jest łatwe tworzenie własnych baz danych do dalszych analiz.